学习笔记

> 更新说明: 本项目与一轮提交的相比,做出了以下调整:
>
> 1. 将数据处理分为dataset和dataloader(分区更有界限些)
> 2. 加入了config.py用以记录参数,路径以及各类列表
> 3. 将predict重分为了evaluate,predict,分别用以画图保存和预测新数据
> 4. 在1~3的基础上对每个板块进行了调整,让项目结构更清晰
> 5. 加入了L2正则方法
> 6. 多采用了ROC图像和混淆矩阵对模型进行评估
> 7. 加入对GPU的选择使用
> 8. 改善精确度和损失
> 9. 处理了Name特征,增加了title的特征
> 10. 提交了多篇各板块学习笔记

专题一：提交内容

1.数据清洗和特征处理方法；

本项目采用了删除特征，根据特点填补缺失值，无量纲化的标准化，创造新特征的方法。具体描述如下：

- 删除特征：训练集中我删除了"PassengerId"（无效），"Survived"（单独处理labal以防止数据泄露），"Ticket"（编号可能隐藏一些信息，比如编号小的可能地位高实力强，但偶然性太大，故舍去），"Cabin"（客舱号缺失太多，且因为人员活动，如果补全并采用可能对模型造成误导，误差大）

- 根据特点填补缺失值：数值型采用中位数填补，如Age,Fare.(不用均值是因为均值受异常值的影响较大)。类别型采用众数填补（有多个众数时选择第一个）

- 无量纲化的标准化：一般对处理后的数据范围没有太严格的要求都选择标准化，而非归一化（标准化受极端异常值的影响较小）（这里有个疑惑，我尝试了筛选标准化之后的数据，显示有超过了【-10，10】的区间的，但打印出来的部分序列数值都很小（没有异常数据））

- 创造新特征：利用SibSp，Parch合并成为了新的特征FamilySize，IsAlone.这些数据可能反馈出，乘客可能因等待生存几率下降，或因互助让生存几率上升。（有了FamilySize，还要创造IsAlone是因为，模型不能清晰认识到独行的影响，FamilySize的1、2、3、4对模型来说是等差的，但其实1和2有着天差地别的差距，所以创造了IsAlone判断是否独行）;也用了Name创造出来了title特征.

- 补充：本题没有异常数据，如果有，可采用如下方法，将异常值归为NaN，再和缺失值一起处理。（如果要删异常值，应该要记录一下哪些数据被删了）

In [ ]:
```
bad = (data['age'] < 0) | (data['age'] > 120)
data.loc[bad, 'age'] = np.nan
```

2.模型结构、损失函数、优化器及主要超参数

- 模型结构：利用nn.Module,构造了一个深度学习的网络，采用了线性函数和激活函数结合，利用Dropout进行正则化（优化时加入了L2正则化，还可以把一些删去的特征加上，并用L1正则化进行间接选择），一共有两个隐藏层（在设置模型时是没有设置输入层的）。 实操时模型采用了先预测，再算Loss，再反向传播、结合Adamw改参数（记得清除之前的梯度），训练完后关梯度，算测试集准确率

- 损失函数：是利用torch中的nn.CrossEntropyLoss（交叉熵损失），适合分类任务，可以在[PyTorch 官方 CrossEntropyLoss 文档] https://pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html 中查看细节（太多了，记不住）

- 优化器：运用Adamw优化器（Adam 优化器是一个能为每个参数调整学习率，并且可以根据梯度进行动态调整的系数优化器。他结合了Momentum和RMSProp的优点,但是Adamw会影响我加入的L2正则

- 主要超参数

超参数	取值
隐藏层神经元数 h1 / h2	32 / 16
Dropout 率	0.2
学习率 lr	0.01
训练轮数 epochs	200
测试集比例	0.2
随机种子	42
优化器	Adamw
WEIGHT_DECAY	0.5

3.数据划分方式、随机种子和实验配置

- 数据划分方式:先将幸存和没幸存分开，打乱后，按训练集、测试集比例将幸存和没幸存划分，再相应地拼装在一起，最后再打乱一次。

- 随机种子：设定了固定种子——42，便于调试，消除部分偶然性

- 实验配置：

1. 运行环境

项	值
操作系统	Windows 11
解释器	pycharm
Python	3.14.7
PyTorch	2.11.0+cu128
NumPy / pandas	2.5.2 / 3.0.5
matplotlib	3.11.1
实际计算设备	**GPU**(也可用CPU进行训练)

2. 产出文件

文件	说明
`model/titanic.pth`	模型权重
`loss_curve.png`	损失曲线
`ROC_curve.png`	ROC曲线
`accuracy_curve.png`	准确率曲线
`titanic学习笔记.ipynb` 等5个	学习笔记

3. 实验结果

指标	数值
首轮 loss	0.6451
末轮 loss	0.3948
最终测试准确率（第 200 轮）	**0.8531**
全程最高测试准确率	**0.8814**
盲猜遇难基线	0.6158
预测示例（一等舱 25 岁女性）	预测幸存，概率为 0.9267
AUC	0.9079195898542904

4.训练过程中遇到的问题及解决方法

内容有些多，单独列了一个专题（见专题2）

5.测试集准确率、实验结果分析和心得体会

- 测试集准确率：可以达到85.31%
- 实验结果分析:损失有较明显的下降，精确度显著增加（显著高于盲猜）,测试集与训练集acc相近,未出现欠拟合与过拟合。AUC约等于0.9,接近1,模型召回率较高,误判率较低
- 心得体会：心得体会不多，但也单列了一个专题（见专题3）

专题二：训练过程中遇到的问题及解决方法

> 说明1：部分由ai生成，再由本人修改

> 说明2：这里只是部分，更多在源代码中有注释

问题	答案
`df: {__getitem__, copy}`	不是可执行代码，是"能力清单"：能 `df['列']` 取值、能 `.copy()`
torch.tensor是什么	相当于 np.array，但能上 GPU、能自动求梯度；是"预处理结果 → 网络"的桥
dtype vs astype 区别	dtype 是**属性**（查现在啥类型）； astype 是**方法**（返回改类型后的新数组）
`np.where(...)[0]` 的 `[0]`	np.where 返回"元组包数组"，[0] 把真正的下标数组剥出来，才能 `[:n]` 切片
FEATURE_ORDER 为何能固定顺序	list 有序 + `feats[ORDER]` 强制重排。网络只认"第几个输入口"，错位会**安静地算错**
函数里的变量怎么搬出去	局部变量函数结束即销毁。正规做法：**一律用 return 传**（可返多个值/字典/对象）
环境/脚本定位	`os.path.dirname(os.path.abspath(__file__))` 拿脚本所在目录

2. 报错表（学长，放下屠刀，这个是ai根据我问他的问题生成的（所以也不太全），我修改成了我能看懂的样子，但我背不到啊~~~）

报错	原因	改法
`KeyError: ['PassengerId'] not found`	同一列被 drop 两次	只留一个 drop
`KeyError: ['FamilySize'] not in index`	FamilySize 是新创造的特征，却在创造前调用	改顺序
`AttributeError: 'tuple' object has no attribute 'drop'`	`return self, df` 打成元组，破坏赋值链	删掉 self
`TypeError: int() ... not DataFrame`	`a.split(df)` 多传的 df 被当 test_size	split 再接收一个 df 形参
`TypeError: module() takes at most 2 arguments (3 given)`	`class Net(nn)` —— nn 是模块不能继承	`class Net(nn.Module)`

报错	原因	改法
`TypeError: empty(): argument 'size' failed...`	`Net(nn.Module)` 把类当维数传进去了	传整数 `Net(ncol)`
`KeyError: ['FamilySize','Sex_male'...] not in index`	用原始 df 取新的特征	`X = df2[ORDER].values.astype('`
`IndexError: Target 1 is out of bounds`	CrossEntropyLoss 要 2，给的 1	模型输出改为2
`Cannot assign modules before Module.__init__()`	漏了 `super().__init__()`	`__init__` 第一行补齐
`ImportError: cannot import name 'draw'`	函数的引用成环了	改成单向，main控制全部
`mat1 and mat2 shapes cannot be multiplied (5x12 and 13x32)`	喂了 12 维	特征按 ORDER 补齐 13 维
`all the input array dimensions must match`	concatenate 时拼不上（维度问题）	竖接看列数、横接看行数
`'numpy.ndarray' object is not callable`	`.values()` 多加了括号	`.values` 无括号
`OMP: Error #15`	torch 与 numpy 各带一份 OpenMP	`main.py` 首行（`import torch` 之`os.environ['KMP_DUPLICATE_LIB_`

专题三：心得体会

二轮再次完善titanic这个项目,有了更多的收获,对于这种模型构建的流程更清晰,也学会了更多的方法,也将一轮留下的优化方向完成了一些,虽然还是有很多要完善的地方(比如学长说的调度器,我对它还有些二懵二懵的,就暂时没加入代码里,暂且作为优化方向继续了解).以下是一些解决了的问题:

1. 什么时候我需要把函数打包成类的形式？什么时候不需要？

*	函数	类
上次的数据	调完就忘	存在 `self` 里
代码量	少、直接	多一个 `__init__` 样板
难度	低	高（self、实例化、方法）
适合	算一下就完事	反复用、要复用
典型	`len()`	`nn.Module`

2. np.where()用法

- np.where 有三参数版本：np.where(条件, A, B) = 满足条件取 A，否则取 B，相当于三元表达式。
- np.where 有另一个用途e.g.surv = np.where(df_survived == 1)[0].先返回哪些位置是Ture,返回的是一个元组，如果是二维的则一个元组记录行坐标，一个元组记录纵坐标，一一对应才有点坐标(至于二维的如何取出为列表，还在研究中)

3. 为什么必须有dataset

- DataLoader 有个硬规矩：只接收 Dataset 对象，不然报错

4. predict里面是需要平均数和方差这两个训练集在main中算出来的数据的。但是我又不能直接从main中去把这两个数据import过来，不然会造成import的循环，那我怎么在predict之中用这两个数据呢?

- 把predict的函数的形参加入mean,std，在main中多输入两个实参，不直接把mean,std搬到predict来

专题四：优化方向

1. 从Name特征中提取出名字长度，同名人数等弱相关特征，用L1正则化间接选择
2. 视情况加入早停(早停需要验证集的加入,而题中明确说了分为训练集和测试集,故而暂时没加早停)
3. 直接用已有函数进行独热编码
4. 加入调度器提高模型的表现
5. 敬请期待!